Lab 8: відповіді

Умова: TASK.md. Дані: lab8/athena/ (SQL і `results/`), lab8/streaming/, lab8/cloud/. Регіон: `us-east-1`.

Part 1. Архітектура Uklon

1. Відставання real-time дороги на 10 хвилин і batch на добу

Коротко. Відставання real-time коштує грошей одразу, бо рішення приймаються на застарілих даних. Відставання batch клієнт не помічає, і воно лікується повторним запуском.

Масштаб 10 хвилин: це 200 пропущених пінгів на водія (600 с / 3 с), авто на 30 км/год проїжджає 5 км, а в черзі стоїть ~4 млн подій (6 713/с × 600 с).

Що	Real-time −10 хв	Batch −1 доба
Matching	Redis тримає позиції 10-хвилинної давнини: призначає далекого водія або того, хто вже зайнятий; подача довша, більше скасувань	не зачіпає
Surge	коефіцієнт із DynamoDB застарів: у дощ ціна низька і водіїв бракує, після піку ціна висока і замовлення губляться	не зачіпає
ETA	модель працює, але на старих позиціях і заторах, тож обіцянка пасажиру неправдива; машина на карті стоїть	модель лишається вчорашньою, точність майже не падає
Звіти	не зачіпає	дашборди в Quick на добу старіші, менеджери рішень на них не приймають
ML	не зачіпає	навчання стартує на даних без останньої доби або чекає; за один день це непомітно

Замовлення й оплата при цьому працюють: ECS і Aurora не залежать від Flink. Дані теж не зникають: Kinesis зберігає лог, Firehose читає його окремо від Flink, тож data lake наповнюється далі.

Як відновлюватись. Real-time: для позицій беремо лише останній пінг водія, бо старі не мають цінності; записи в Redis живуть із TTL, а surge за застарілих даних падає до безпечного значення. Batch: запускаємо нічний Glue job повторно по сирих даних у S3.

Де межа. Доба відставання безпечна, поки відстає Glue, а не Firehose. Стандартне зберігання в Kinesis становить 24 години, тож зупинка Firehose на такий самий час уже означає втрату сирих подій.

2. Чому GPS не йде через Lambda

Навантаження. 580 млн пінгів на добу / 86 400 с ≈ **6 713 пінгів/с** у середньому, у піки більше. На місяць: 580 млн × 30 = **17.4 млрд**.

Вартість на місяць (17.4 млрд = 17 400 млн). Ціни з AWS Price List, `us-east-1`, жовтень 2026, без free tier. Припущення: Lambda x86, 128 МБ, 50 мс на виклик.

Сервіс	Арифметика	$/міс
Lambda, запити	17 400 млн × $0.20/млн	3 480

Сервіс	Арифметика	$/міс
Lambda, час	17.4 млрд × 0.05 с × 0.125 ГБ = 108.75 млн ГБ·с × $0.0000166667	1 813
Lambda разом		**≈ 5 290**
API Gateway REST	333 × $3.50 + 667 × $2.80 + 16 400 × $2.38 = 1 166 + 1 868 + 39 032	**≈ 42 070**
API Gateway HTTP API	300 × $1.00 + 17 100 × $0.90 = 300 + 15 390	**≈ 15 690**
IoT Core, повідомлення	1 000 × $1.00 + 4 000 × $0.80 + 12 400 × $0.70 = 1 000 + 3 200 + 8 680	12 880
IoT Core, з'єднання	~20 тис. водіїв онлайн × 43 200 хв = 870 млн хв × $0.08/млн	70
IoT Core, правило і дія	17 400 млн × ($0.15 + $0.15)/млн	5 220
IoT Core разом		**≈ 18 170**

20 тис. водіїв: 580 млн / 28 800 пінгів на добу від одного водія (86 400 с / 3 с). Kinesis потрібен в обох варіантах, тому його не рахуємо.

Висновок щодо ціни. REST + Lambda ≈ **$47 тис./міс**, HTTP API + Lambda ≈ **$21 тис./міс**, IoT Core ≈ **$18 тис./міс**. Проти REST виграш очевидний, проти HTTP API невеликий. Велика економія з'являється з Basic Ingest: повідомлення йдуть напряму в правило без оплати за messaging, і лишається ~$5.3 тис./міс (70 + 5 220). Тож ціна важлива, але вирішують і технічні причини нижче.

Технічні причини:

- **Постійне з'єднання.** Lambda не має стану і не тримає з'єднання. HTTP кожні 3 с несе заголовки на кожен запит, а на поганій мобільній мережі ще й нові TCP і TLS handshake. MQTT відкривається один раз, його фіксований заголовок має 2 байти: менше трафіку й витрат батареї. Цим самим з'єднанням можна слати дані водієві, а last will повідомляє про обрив.
- **Порядок подій.** Паралельні виклики Lambda порядку не гарантують: пінг із секунди 6 може обігнати пінг із секунди 3. У Kinesis із ключем `driverId` усі пінги водія йдуть в один шард і читаються по порядку.
- **Паралельність.** 6 713/с × 0.05 с ≈ 336 одночасних виконань у середньому, а за 150 мс уже ~1 000, тобто стандартна квота акаунта. Будь-яке уповільнення залежності впирається в throttling.
- **Cold start.** За постійного навантаження середовища теплі, тож це не головна причина. Він б'є під час піків і деплоїв: сотні мілісекунд на нових середовищах, а це хвіст затримки в дорозі, що має відповідати за секунди.

Де Lambda доречна. Не на кожен пінг, а на пачку: споживач Kinesis із batch 100 дає 174 млн викликів, тобто ~$35/міс за запити. Саме так Lambda працює і в схемі Uklon: на новий файл у S3, а не на кожну подію.

3. Що стартап викине першим і що втратить

Лишаються ALB, ECS, одна БД (RDS замість Aurora) і S3. Решта викидається приблизно в такому порядку:

Порядок	Викидаємо	Чим замінити	Що втрачаємо
1	SageMaker	ETA з routing API (OSRM, Google) × коефіцієнт години доби	точність ETA і прогноз попиту; даних на навчання все одно ще мало
2	Flink	cron щохвилини: SQL «замовлення / вільні водії» по районах	вікна event time, стан, реакцію за секунди; surge стає грубшим

Порядок	Викидаємо	Чим замінити	Що втрачаємо
3	DMS	нічний експорт із read replica у S3	зміни майже в реальному часі та проміжні стани рядків
4	Glue job	Athena CTAS за розкладом, схема вручну (як у Part 2)	Spark для важких трансформацій; Data Catalog лишається, ним користується Athena
5	IoT Core	HTTP POST на ECS кожні 5–10 с, позиції в Redis	економію батареї й трафіку, зворотний канал до водія, last will

Заміна IoT Core працює завдяки масштабу: 500 водіїв із пінгом раз на 5 с дають 100 запитів/с, і це витримує той самий ALB. Без Flink і DMS зникає й потреба в Kinesis, тому стартап позбувається ще й постійної плати за стрім.

Спільна втрата: стартап міняє запас масштабу на простоту. Це вигідно, доки навантаження мале, але зворотний перехід потім коштує міграції, найперше мобільного клієнта на MQTT.

Part 2. Batch

Масштаб

Показник	Значення
Подій у `payment_events`	3 030 197
Унікальних `invoiceId`	1 000 000
Точних дублікатів	30 197 (1.0% подій)
Частка подій із запізненням понад годину	**0%** (0 подій, максимум 600 с)

Без дублікатів лишається рівно 3 000 000 подій, тобто по 3 на платіж. Запізнення понад годину немає, бо генератор затримує події на 1–10 хв. Дані: 07_scale.csv.

`dt` це день `modifiedDate`. Тому `dt=2026-10-31` містить лише 5 подій: це хвіст платежів, створених 30 жовтня наприкінці доби. Фактично датасет покриває 30 днів.

Результати запитів 2–6

Повні результати: lab8/athena/results/.

Запит 2. View `payments`: 1 000 000 рядків, по одному на `invoiceId`.

Статус	Платежів	Частка
`success`	939 820	93.98%
`failure`	60 180	6.02%

Запит 3. Оборот, топ-3 мерчанти в кожній валюті. У кожній валюті 10 мерчантів. Валюти не додаємо між собою.

Валюта	Мерчант	Платежів	Оборот
UAH	Інтернет-магазин	87 115	310 259 259.21
UAH	АЗС	87 560	144 641 341.06

Валюта	Мерчант	Платежів	Оборот
UAH	Квитки	87 303	77 749 863.65
USD	Інтернет-магазин	3 725	13 840 942.83
USD	АЗС	3 600	5 856 481.33
USD	Квитки	3 876	3 602 313.89
EUR	Інтернет-магазин	2 840	10 084 500.30
EUR	АЗС	2 873	4 708 258.32
EUR	Квитки	2 745	2 451 613.23

Усього: 726 040 513.31 UAH, 31 656 774.19 USD, 23 400 058.37 EUR. Кількість платежів у мерчантів майже однакова, тож різницю в обороті дає середній чек.

Запит 4. Failure rate, 3 найвищі й найнижчий із 12 комбінацій.

paymentMethod	device	Платежів	Невдалих	Частка
qr	android	6 675	448	6.71%
apple_pay	android	83 677	5 130	6.13%
google_pay	web	59 996	3 645	6.08%
qr	ios	6 795	402	5.92%

Майже всі комбінації лежать у межах 5.9–6.1%. Вирізняється лише `qr`/`android`, але на вибірці в 27 разів меншій за `card`/`android`.

Запит 5. Пікові години (UTC).

Година	Платежів
18	80 338
19	73 167
17	72 905
4 (мінімум)	6 585

Є три хвилі: близько 8, 12 і 18 години. Вночі (0–4) лише ~6 600 платежів на годину, у 12 разів менше за пік.

Запит 6. Запізнілі події: 60 824 із 3 030 197 подій (2.007%) прийшли пізніше ніж за 60 с. Це збігається із заявленими ~2%.

JSON проти Parquet

Дані: stats.csv, час Total, по одному запуску на запит. Ціна $5/TB, мінімум оплати 10 МБ на запит.

Запит	JSON: scanned	JSON: час	Parquet: scanned	Parquet: час	Дешевше за сканом	Дешевше за рахунком
3. Оборот	1 260.69 МБ	4.87 с	5.00 МБ	1.18 с	252×	126×
4. Failure rate	1 260.69 МБ	3.90 с	0.57 МБ	1.23 с	2 214×	126×

Запит	JSON: scanned	JSON: час	Parquet: scanned	Parquet: час	Дешевше за сканом	Дешевше за рахунком
5. Пікові години	1 260.69 МБ	3.36 с	3.78 МБ	1.62 с	334×	126×

Висновок. За обсягом скану Parquet дешевший у **252–2 214 разів**, а за реальним рахунком у **126 разів**: $0.0063 проти $0.00005 за запит. Усі три Parquet-запити сканують менше 10 МБ, тому платять однаковий мінімум. Швидше вони лише в 2–4 рази, бо на такому обсязі значну частку часу займають накладні витрати самого запиту. Результати на обох форматах збігаються рядок у рядок.

Економія складається з трьох частин:

- **Колонки.** JSON читається весь, а Parquet лише потрібні колонки. Тому запит 4 із трьома короткими колонками сканує найменше.
- **Стиснення.** Весь `curated/` займає 52 МБ проти 1 261 МБ сирого JSON.
- **Дедуплікація наперед.** У Parquet лежить 1 млн рядків замість 3 млн, а запит на JSON щоразу виконує дедуплікацію заново. Тож частина виграшу в часі йде від цього, а не від формату.

CTAS один раз сканує 1.26 ГБ, тобто коштує як один запит на JSON, і окупається вже на другому запиті.

Чому DISTINCT перед row_number() і що ламається без дедуплікації

Чому саме в такому порядку. Якщо поставити `DISTINCT` після `row_number()`, він нічого не прибере: дублікати отримають різні `rn` і вже не будуть однаковими рядками. Тому спочатку прибираємо дублікати, а потім нумеруємо.

Приклад: платіж із дубльованою подією `success`.

`modifiedDate`	`status`	`rn` без DISTINCT	`rn` із DISTINCT
08:15:31	`success`	1	1
08:15:31	`success` (дубль)	2	прибрано
08:15:27	`processing`	3	2
08:15:22	`created`	4	3

Для самого фільтра `rn = 1` результат тут однаковий: `row_number()` вибере один із двох ідентичних рядків, і байдуже який. `DISTINCT` стає потрібним в інших місцях:

- `rn = 2` має означати попередній статус. Без `DISTINCT` це знову `success`, а не `processing`.
- `rank()` дав би обом дублікатам 1, і платіж порахувався б двічі.

Однаковий `modifiedDate` у різних статусів. Цей випадок `DISTINCT` не вирішує: рядки відрізняються статусом, тож обидва лишаються.

`modifiedDate`	`status`	`finalAmount`
08:15:31	`processing`	0
08:15:31	`success`	45000

`ORDER BY modifiedDate DESC` бачить нічию, і `row_number()` вибирає рядок довільно, причому між запусками вибір може змінюватись. Якщо випаде `processing`, успішний платіж зникне з обороту. Це справжній ризик, бо дати мають точність до секунди. Лікується другим ключем сортування за стадією

статусу:

```
ORDER BY from_iso8601_timestamp(modifiedDate) DESC,
         CASE status WHEN 'created' THEN 1 WHEN 'processing' THEN 2 ELSE 3 END DESC
```

У наших даних таких нічиїх **0** на весь місяць (13_ties_check.csv), тому view працює коректно і без цього ключа. Для продакшену він потрібен.

Що ламається без дедуплікації. Числа: 12_no_dedup_impact.csv.

Показник	Без дедуплікації	Правильно	Похибка
Кількість платежів (рядки)	3 030 197	1 000 000	у 3 рази
Успішні платежі	949 199	939 820	+9 379 (+1.0%)
Невдалі платежі	60 779	60 180	+599 (+1.0%)
Оборот, UAH	733 128 678.76	726 040 513.31	+7 088 165.45 (+0.98%)
Оборот, USD	31 935 909.60	31 656 774.19	+279 135.41 (+0.88%)
Оборот, EUR	23 647 987.04	23 400 058.37	+247 928.67 (+1.06%)
Failure rate, `failure` / усі рядки	2.01%	6.02%	занижений утричі
Failure rate, `failure` / (`success` + `failure`)	6.018%	6.018%	майже нуль

Найдорожча помилка це оборот: фінансовий звіт завищено на 7 млн грн, і без звірки цього не помітити.

Failure rate на цих даних **не завищується**. Дублікати випадкові й потрапляють в обидва статуси рівномірно, тож чисельник і знаменник ростуть разом. Завищеним він був би, якби `failure` дублювався частіше за `success`, наприклад через повторні спроби доставки webhook. Абсолютна кількість невдалих платежів при цьому завищена, а частка від усіх рядків занижена, бо в знаменнику опиняються `created` і `processing`.

Way B: Glue Crawler

Crawler `lab8-payments-crawler` працював ~70 с і створив одну таблицю `lab8_crawler.payments`. Схема: crawler_schema.json. Обидві таблиці читають ті самі дані: 3 030 197 рядків, 60 779 значень `failureReason`, однакова сума `amount`.

Поле	Наш DDL	Crawler
`amount`, `finalAmount`	`bigint`	`int`
`ccy`, `mcc`	`int`	`int`
`createdDate`, `modifiedDate`, `receivedAt`	`string`	`string`
`failureReason`	`string`	`string`, остання колонка
`dt`	партиція, `string`	партиція, `string`
SerDe	`org.openx.data.jsonserde.JsonSerDe`	той самий

Типи `amount`, `ccy` і дат, партиція `dt`. Для `amount` і `finalAmount` crawler вибрав `int`, для `ccy` теж `int`. Дати лишились `string`: у JSON немає типу дати, і crawler не перетворив ISO-рядки на `timestamp`. `dt` він розпізнав як партицію за шляхом `dt=.../` і зареєстрував усі 31 партицію без `MSCK REPAIR`.

Що сталося з `failureReason`. Crawler об'єднав схеми файлів, і поле є в таблиці як `string`. У рядках без нього значення `NULL`. Це видно й на рівні партицій: поле є у 30 із 31, бо в `dt=2026-10-31` немає жодного `failure`. Запити це не ламає, бо схема таблиці спільна.

Яка схема зручніша і чому схеми вручну досі поширені. Для наших запитів різниці немає, результати однакові. Crawler зручніший на старті: не треба знати структуру, а нові партиції він додає сам. Для постійної роботи кращий ручний DDL:

- **Crawler виводить типи зі значень, а не з сенсу.** `int` вміщує максимум 2 147 483 647 копійок, тобто ~21.5 млн грн на платіж. Наразі цього вистачає, але схема тримається лише на тому, що такої суми ще не було. Ми ж свідомо взяли `bigint`.
- **Схема є контрактом.** Вона лежить у git, проходить review і не зміниться сама. Повторний запуск crawler може змінити типи чи колонки, якщо в даних з'явиться щось нове, а зламаються вже чужі запити.
- **Метадані crawler наближені.** Він записав `recordCount = 1 202 922`, хоча рядків 3 030 197.
- **Дати все одно потребують рішення людини.** Ні crawler, ні наш DDL не дали `timestamp`, тому перетворюємо їх через `from_iso8601_timestamp`.

На практиці підходи поєднують: crawler для розвідки нових даних, а ручна схема для того, на що спираються звіти.

Part 3. Streaming локально

Вивід consumer: outputs/. Усі запуски наживо, 20 платежів/с (60.6 повідомлень/с), денний зріз дня 2026-10-01: вночі `n` у вікнах надто мале.

Watermark рахується окремо для кожної партиції: це мінімум із їхніх максимумів `modifiedDate`, мінус `lateness`. Один максимум на весь потік не працює на черзі: Kafka віддає партиції пачками, і вчасні події виглядають запізнілими. На тому самому топіку з 2000 подій глобальний watermark відкинув **1 118 подій (56%)** і дав 18 алертів замість 42 (лог), а per-partition 12 подій і 42 алерти (лог).

Експеримент 1. Зупинка consumer

Що робили. 10 000 подій, consumer зупинено через ~60 с на ~60 с, producer працював далі. Паралельно на тому самому потоці йшла друга група, яку вбили через `kill -9`. Логи: restart.log, restart-kill9.log, офсети: restart-offsets.txt.

Подій не втрачено. Kafka тримає лог, а група пам'ятає свій офсет:

Момент	Закомічений офсет	Log end	Lag
Через 3 с після зупинки	3 609 (1162 + 1135 + 1312)	3 804	195
Перед рестартом	3 609	7 089	3 480
Кінець	10 000 (3275 + 3226 + 3499)	10 000	0

`consumed` зійшовся: **3 609 + 6 391 = 10 000 = відправлено**. Другий запуск почав рівно з офсету 3 609.

Перша спроба дала 9 999. Це був наш баг: обробник сигналу кидав виняток між `poll()` і `process()`, і вже отримане повідомлення пропадало, хоча його офсет комітився. Тепер сигнал лише ставить прапорець, а офсет зберігається після обробки.

Що втратилось разом із пам'яттю. Офсет живе в Kafka, а множина дедуплікації, відкриті вікна і watermark живуть у процесі.

Показник	Ctrl+C	`kill -9`
Офсет, з якого почав другий запуск	3 609	3 372 (останній автокоміт)
Прочитано повторно	0	~237 подій (~4 с)
Вікна 08:32–08:34, правда 88 фінальних подій	**12**	**84**
Усього n у вікнах, правда 3 299	3 098	3 172
Клітинок вікно+метод понад правду	0	0
Вікон, надрукованих двічі	0	2

Що могло подвоїтись:

- **Після Ctrl+C нічого.** Жодна подія не читалась двічі, дублікатів знайдено 101 із 101. Дубль міг би проскочити, лише якщо рестарт припаде рівно між ним і оригіналом, а в цих даних вони завжди йдуть підряд.
- **Після `kill -9` події обробляються двічі.** Consumer прочитав приблизно 3 609 + 6 628 ≈ 10 237 подій на 10 000 відправлених, а порожня множина не впізнала ~237 повторів. Це at-least-once: нічого не губиться, зате можливі повтори.
- **У вікнах цього разу подвоєння не сталося, але випадково.** Повторні події (~2.4 хв event time) лягли у вікна, які були ще відкриті й померли разом із процесом. Це повернуло їхні числа: 84 із 88 проти 12 після Ctrl+C. Якби останній коміт був старший за `lateness`, подія потрапила б у вже надруковане вікно і порахувалась удруге. За `lateness=0` це майже гарантовано.
- **Закрите вікно може відкритись знову.** Після рестарту watermark порожній, тож запізнілу подію, яку вже відкинули, приймуть. Так вікна 08:24 і 08:25 для `card` надруковані двічі: `n=19`, потім `n=1`. Сума тут правильна, але споживач цих рядків отримає два результати на вікно.

Головна шкода тут не подвоєння, а **неповні вікна**. Після Ctrl+C вікно 08:34 для `card` мало `n=7, share=14.3%` і дало хибний ALERT. Насправді там `n=19`, 1 помилка, 5.3%. Лікується спільним станом: контрольні точки Flink зберігають вікна й офсети разом.

Експеримент 2. Два consumer в одній групі

Що робили. Два consumer у групі `lab8`, другий приєднався через 9 с, 6 000 подій. Вивід `rpk group describe`: two-consumers-group.txt.

Consumer	Партиції	`consumed`	Дублікатів	Алертів
A	2	2 196	22	15
B	0, 1	3 804	39	31
Разом	3	**6 000**	61	46

Коли приєднався B, A віддав усі партиції (`REVOKED [0, 1, 2]`) і отримав лише `[2]`: це rebalance, балансер `range`. Кожну партицію читає рівно один член групи, тому події не повторились і не загубились: 2 196 + 3 804 = 6 000 = відправлено, кінцевий lag 0.

Третій consumer ще працював би, четвертий простоював би: партицій лише 3.

Обмеження. Кожен consumer бачить лише свої партиції, тому вікна часткові. Вікно 08:30 для `card` розпалось на `n=2` в A і `n=4` у B, і жодне окреме число не правильне. A показав 50%, але поріг `n ≥ 5` його відсік. Ключ `invoiceId` тримає разом події платежу, а не події метода оплати. Щоб рахувати частку по `paymentMethod` кількома consumer, треба або ключувати за методом, або збирати часткові результати на наступному кроці.

Експеримент 3. Producer валить 30% платежів

Що робили. 12 000 подій із 17:00, `--fail-rate 0.3`. Контроль: той самий зріз без помилок (baseline.log). Лог: fail30.log.

Показник	Baseline	fail30
Фінальних подій у вікнах	3 781	3 781
Failure share	5.79%	**33.43%**
Клітинок із `n ≥ 5`	257	257
ALERT	59 (23.0%)	**248 (96.5%)**

Перші рядки:

```
ALERT 2026-10-01T17:00:00Z method=apple_pay n=6 share=16.7%
ALERT 2026-10-01T17:00:00Z method=card n=22 share=50.0%
ALERT 2026-10-01T17:00:00Z method=google_pay n=5 share=20.0%
ALERT 2026-10-01T17:01:00Z method=apple_pay n=7 share=57.1%
ALERT 2026-10-01T17:01:00Z method=card n=17 share=23.5%
ALERT 2026-10-01T17:01:00Z method=google_pay n=5 share=40.0%
```

Алерт спрацював уже на першому закритому вікні, share виріс з ~6% до ~33% за всіма методами. Очікуване значення: 6% + 94% × 30% ≈ 34%.

Висновок про поріг. Baseline теж дав 59 алертів без жодної аварії. За частки 6% і `n` від 5 до 20 дві-три помилки випадково дають понад 10%. Для продакшну поріг слабкий: треба більше `n`, кілька вікон поспіль або статистичний інтервал.

Експеримент 4. Очікування запізнілих = 0

Що робили. Два consumer у різних групах читали один живий потік: 12 000 подій із 17:00. Логи: baseline.log, lateness0.log.

Показник	`lateness=120`	`lateness=0`	Різниця
`late_dropped`, усі події	202 (1.68%)	243 (2.03%)	+41
`late_final`, фінальні статуси	72	91	+19
ALERT	59	58	−1

Порівняння на однакових 338 клітинках вікно+метод, бо `lateness=0` закриває вікна раніше й устигає закрити більше:

	Правда	lateness=120	lateness=0
Подій у вікнах	3 853	3 781	3 762
Із них `failure`	221	219	217
Failure share	5.74%	5.79%	5.77%

Що змінилось у вікнах. Частина фінальних статусів відкинута: 19 подій зникли з 18 клітинок із 338. У цих клітинках `share` змінився в середньому на 0.86 в. п., максимум на 5 в. п. Один алерт зник (17:32, `apple_pay`), але не через частку: `n` упало з 5 до 4 і не пройшло поріг.

Чи зміщений `share`. Систематично ні. Зміщення було б, якби `failure` запізнювались інакше за `success`, а це не так. На всьому місяці понад 60 с запізнюються 1.97% `failure` і 2.02% `success` (14_lateness_by_status.csv). Відкидання запізнілих прибирає події майже випадково, тож загальна частка стоїть на місці (5.79% проти 5.77%), а страждають окремі малі вікна: там один рядок рухає `share` на відсотки. У реальній системі зсув цілком можливий: наприклад, якби помилки йшли через повільніший шлях webhook, частка була б заниженою.

Навіщо тоді чекати. 2 хвилини зберегли лише 19 із 91 фінальної події: запізнення лежить у межах 1–10 хв, тож більшість подій приходить пізніше за очікування. Щоб не втратити нічого, треба `lateness=600`, але тоді кожне вікно і кожен алерт закриваються на 10 хв пізніше. Це компроміс між повнотою і затримкою. Відкинуте не зникає: у batch-дорозі ті самі події порахує Athena.

Необмежена множина дедуплікації

`seen` росте на ~100 тис. ключів за день, ніколи не чиститься і зникає з рестартом, тому в продакшні потрібне сховище з TTL. Є два варіанти:

- **Redis:** команда `SET dedup:<key> 1 NX EX <ttl>` на кожну подію. Вона атомарна, і `NX` одразу каже, чи ключ уже був. Це окремий ключ із TTL, а не тип даних Set: у елементів Set власного TTL немає. Сховище спільне для всіх consumer і переживає рестарт.
- **Стан Flink із TTL:** `StateTtlConfig` на keyed state за `invoiceId`. Стан лежить у контрольній точці разом з офсетами й вікнами, тому рестарт відновлює все узгоджено. Це закриває і втрату вікон з експерименту 1, якщо вони теж у Flink.

Як вибрати TTL. TTL ≥ максимальне запізнення + час ретраїв webhook, із запасом. Дубль має застати ключ живим, тож TTL мусить покривати найдовший шлях повторної доставки. У наших даних запізнення до 600 с, а дублікати йдуть підряд, тож вистачило б 15 хв. Але реальний провайдер може ретраїти годинами. Якщо ретраї тривають до 24 год, беремо ~25 год.

Помилки несиметричні: закороткий TTL пропускає дублікати і псує числа, задовгий лише коштує пам'яті. При 100 тис. подій на день і ~100–200 Б на ключ доба займає ~10–20 МБ, тож TTL варто брати з запасом.

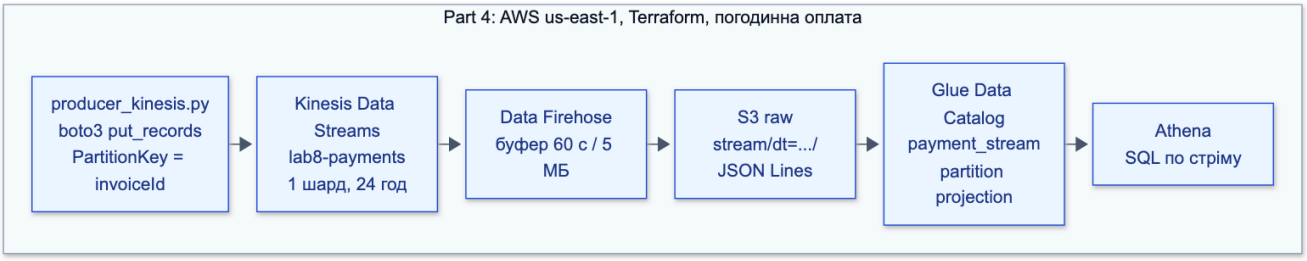
Part 4. Streaming у хмарі

Той самий датасет, перші 20 000 подій дня 2026-10-01, ~10 хв при 33 записах/с. Інфраструктура: Terraform, PR #5. Продюсер: додаток A. Дані: lab8/cloud/results/.

Від схеми з умови є два відступи: немає гілки Lambda → SNS, а замість Glue Crawler використано таблицю з partition projection, тож `MSCK` і краулер не потрібні.

Спочатку Kinesis і Firehose були недоступні: на AWS Free plan будь-який виклик повертав `SubscriptionRequiredException`. Пайплайн запрацював після переходу на Paid plan.





Що дійшло

Етап	Значення
Продюсер	20 000 відправлено, сума `FailedRecordCount` 0
Kinesis `IncomingRecords`	20 000
Firehose `DeliveryToS3.Records`	20 000, 11 файлів, у `stream-errors/` порожньо
S3	8 321 971 байт, збігається з вихідними даними до байта
Athena	20 000 рядків

Запит по статусах (01_stream_by_status.csv):

Статус	Подій	`min(receivedAt)`	`max(receivedAt)`
`created`	6 671	2026-10-01T00:00:02Z	2026-10-01T09:18:05Z
`processing`	6 668	2026-10-01T00:00:03Z	2026-10-01T09:18:04Z
`success`	6 248	2026-10-01T00:00:15Z	2026-10-01T09:18:04Z
`failure`	413	2026-10-01T00:01:48Z	2026-10-01T09:17:53Z

Дедуплікація, як у view `payments` (02_stream_dedup.csv): 6 602 платежі, з них `success` 6 183, `failure` 410, `processing` 7, `created` 2. Обидва результати збігаються з підрахунком із вихідного файлу. Дев'ять незавершених платежів це не помилка: `--limit` обрізав потік, і їхні фінальні події не були надіслані.

Три спостереження:

- **Дублікати дійшли до S3.** 214 із 20 000 подій повторні: Firehose нічого не дедуплікує, це робить SQL.
- **`dt` це час прибуття.** Усі події мають `dt=2026-11-06`, хоча `modifiedDate` жовтневий. Партиції стріму кажуть, коли дані дійшли, а не коли вони сталися.
- **`\n` спрацював.** 20 000 рядків в 11 файлах: без роздільника Athena прочитала б один рядок на файл.

Відмінності від локального Redpanda

	Redpanda (Part 3)	Kinesis + Firehose (Part 4)
Керування	свій контейнер: запуск, оновлення, диск	керований сервіс, серверів немає
Паралелізм	партиції, 3 у топіку	шарди, 1 у стрімі; ліміт 1 000 записів/с або 1 МБ/с на шард
Зберігання	поки живе контейнер	24 години, далі дані зникають
Споживач	наш `consumer.py`	Firehose, без нашого коду
Обробка	дедуплікація, вікна й алерт	лише доставка у файли; вікон без Flink немає
Затримка	секунди	~65 с: останній запис надіслано о 19:12:46, останній файл у S3 о 19:13:51
Час	вікна за `modifiedDate`, watermark	`dt` за часом прибуття у Firehose
Дублікати	відкидає consumer	лежать у S3, прибираються в SQL
Часткова відмова запису	брокер підтверджує кожне повідомлення	`put_records` не кидає винятку, треба читати `FailedRecordCount`
Ціна	$0	погодинно за шард, навіть без трафіку

Головна різниця: Redpanda разом із нашим кодом рахувала результат сама, а хмарний пайплайн лише доставляє дані в озеро. Щоб отримати алерт, потрібен ще один споживач: Lambda чи Flink.

Вартість

Обсяги виміряні, ціни зі сторінок AWS pricing і AWS Price List (`us-east-1`). Це розрахунок за цінами, а не рядок із рахунку: білінг AWS оновлюється із затримкою.

Стаття	**Арифметика**	**$**
Шард	1 шард-год × $0.015 (верхня межа)	0.01500
PUT payload units	20 000 записів до 25 КБ = 20 000 одиниць × $0.014/млн	0.00028
Firehose	20 000 × 5 КБ = 0.1 ГБ × $0.029	0.00290
Athena	5 запитів × мінімум 10 МБ × $5/ТВ	0.00025
Разом		**≈ 0.018**

- Шард жив ~22 хв (19:01:39–~19:23 UTC). Сторінка цін не каже, як рахуються неповні години, тому беру цілу годину. Пропорційно було б $0.0055, а разом ~$0.009.
- Firehose округлює кожен запис до 5 КБ: наші 416 Б оплачуються як 5 КБ, тобто 0.1 ГБ замість 8.3 МБ. На дрібних записах це 12-кратна переплата.
- Запит сканував 8.32 МБ, а оплачується мінімум у 10 МБ.
- PUT-запити S3 і зберігання 8 МБ менші за цент, тому не враховані.

Майже вся сума це час шарда: забутий стрім коштує $0.36 на добу і ~$11 на місяць незалежно від трафіку. Тому вся інфраструктура стоїть за змінною `enable_lab8_stream`.

Прибирання

Стрім вимкнено через `enable_lab8_stream = false` (PR #7): план `5 to destroy`, застосовано в HCP. Після цього `aws kinesis list-streams` і `aws firehose list-delivery-streams` повертають порожні списки, роль `lab8-firehose` видалена.

Файли в `stream/` лишились, бо бакет поза Terraform. Таблицю `payment_stream` після цього відтворено запитом `00_stream_table.sql` над тими самими файлами, щоб зробити скріншот. Запит дав той самий результат, що й під час роботи стріму. Це лише метадані: погодинної оплати немає.

Для обговорення в класі

Event time проти processing time

- Наші вікна використовують **event time** (`modifiedDate`): результат не залежить від того, коли подія дійшла. Processing time (`receivedAt`) розмазав би пік і переніс би події в чужі хвилини.
- Час рухають самі події через watermark, а не годинник: replay стискає добу приблизно в 50 разів.
- Подія в межах очікування потрапляє у своє вікно, пізніша рахується як `late_dropped`. У датасеті 2.007% подій запізнюються понад 60 с, максимум 600 с.
- Очікування це компроміс між повнотою і затримкою: 2 хв врятували лише 19 із 91 фінальної події, а повний захист означає алерт на 10 хв пізніше.
- Відкинуте в stream не зникає: batch порахує ці події наступної ночі.

Чому ті самі дані зберігають двічі

- **JSON** це сире джерело правди: зберігає все як прийшло, тож можна перерахувати історію після помилки в логіці чи зміни схеми.
- **Parquet** це формат для читання: колонки, стиснення, уже без дублікатів. 1 261 МБ стали 52 МБ, скан упав у 252–2 214 разів, рахунок у 126 разів.
- Сховище дешевше за повторне сканування: CTAS окупився вже на другому запиті.
- Parquet можна будь-коли відтворити з JSON, навпаки ні: дублікати й проміжні статуси вже відкинуті.

Коли досить нічного batch

- Досить, коли рішення приймають люди й не щохвилини: фінансові звіти, аналітика для продакт-менеджерів, навчання моделей. Відставання на добу лікується повторним запуском.
- Секунди потрібні, коли рішення автоматичне і застаріває: матчинг, surge, антифрод, алерт про збій оплат. Дані 10-хвилинної давнини там уже шкодять.
- Ціна streaming це постійно ввімкнений сервіс і складність: watermark, запізнілі події, стан і рестарти. Частина 3 показала це наочно: після рестарту неповне вікно дало хибний ALERT.
- Практичне правило: починати з batch і додавати streaming для конкретного рішення, де важливі секунди.

Що дає керований сервіс і чого це коштує

- **Дає:** немає брокерів, дисків, оновлень і реплікації; масштабування шардами; готову доставку в S3 без нашого коду; Crawler за ~70 с описав 3 млн подій без жодного DDL.
- **Коштує:** погодинна оплата навіть без трафіку, менше контролю (Firehose не рахує вікон), прив'язка до хмари.

- **І доступність:** Part 4 спочатку зупинився не на коді, а на плані акаунта: Free plan не дає Kinesis. Локальний Redpanda такого обмеження не має.
- Self-hosted Kafka дешевша за інфраструктурою лише на великому постійному обсязі, бо вимагає людей. Для лабораторної цілком вистачило одного контейнера.

Необмежена множина побачених подій

Див. Part 3: Redis або стан Flink із TTL, TTL ≥ максимальне запізнення + час ретраїв webhook.

Додаток А. Код продюсера

lab8/cloud/producer_kinesis.py

```
"""Lab 8, Part 4: той самий replay, що в Part 3, але в Kinesis Data Streams.

Приклади:
    python producer_kinesis.py --limit 2000 --rate 20 --start-at 17:00
    python producer_kinesis.py --limit 2000 --rate 20 --start-at 17:00 --fail-rate 0.3
"""

import argparse
import json
import sys
import time
from pathlib import Path

import boto3

# Спільна логіка лежить поруч із продюсером Part 3. Це окремий скрипт, а не пакет,
# тому додаємо теку в шлях імпорту вручну.
STREAMING_DIR = Path(__file__).resolve().parent.parent / "streaming"
sys.path.insert(0, str(STREAMING_DIR))

from replay import prepare_events  # noqa: E402

DEFAULT_FILE = STREAMING_DIR / "data" / "events.jsonl"
# Межа API: не більше 500 записів в одному виклику PutRecords.
MAX_BATCH = 500
# Відправляємо раз на секунду, навіть якщо пачка неповна: при 60 повідомленнях/с
# чекати 500 записів означало б затримку у 8 секунд.
FLUSH_SECONDS = 1.0
MAX_RETRIES = 5


def parse_args():
    parser = argparse.ArgumentParser(description="Replay payment events into Kinesis")
    parser.add_argument("--file", type=Path, default=DEFAULT_FILE)
    parser.add_argument("--stream", default="lab8-payments")
    # Явно, бо регіон за замовчуванням у цьому акаунті eu-north-1, а стрім живе в us-east-1.
    parser.add_argument("--region", default="us-east-1")
    parser.add_argument("--rate", type=float, default=20.0, help="платежів за секунду")
    parser.add_argument("--fail-rate", type=float, default=0.0, help="частка success, що стане
failure")
    parser.add_argument("--limit", type=int, default=None, help="надіслати лише N записів")
    parser.add_argument("--start-at", default=None, help="почати з цього часу receivedAt, HH:MM
(UTC)")
    parser.add_argument("--seed", type=int, default=42, help="seed для --fail-rate")
```

```
    return parser.parse_args()


def to_record(event):
    return {
        # Firehose склеює записи в один файл без роздільника. Без '\n' вийшов би один довгий рядок
        # на файл, а JSON SerDe читає файл порядково: Athena побачила б лише один рядок із файлу.
        "Data": (json.dumps(event, ensure_ascii=False) + "\n").encode(),
        # Ключ хешується в шард, тому всі події платежу йдуть в один шард і зберігають порядок.
        # Зараз шард один, але ключ потрібен, щоб код не зламався зі збільшенням їх кількості.
        "PartitionKey": event["invoiceId"],
    }


def put_batch(client, stream, records):
    """Надсилає пачку, повторює відхилені записи. Повертає (сума FailedRecordCount, кількість
недоставлених)."""
    failed_total = 0
    pending = records

    for attempt in range(MAX_RETRIES + 1):
        response = client.put_records(StreamName=stream, Records=pending)
        failed = response["FailedRecordCount"]
        failed_total += failed
        if failed == 0:
            return failed_total, 0

        # Головна пастка PutRecords: виклик успішний, навіть якщо частина записів відхилена.
        # Винятку не буде, тому FailedRecordCount треба перевіряти самим. Відповідь іде в тому самому
        # порядку, що й запит, а відхилений запис має поле ErrorCode. Повторюємо лише такі.
        pending = [
            record
            for record, result in zip(pending, response["Records"], strict=True)
            if "ErrorCode" in result
        ]
        if attempt < MAX_RETRIES:
            # Найчастіша причина це ліміт шарда, тож пауза росте: 0.1, 0.2, 0.4 с і далі.
            # Повторений запис потрапляє в шард після сусідів, тому порядок може порушитись.
            # Це нормально: consumer рахує за event time, а не за порядком прибуття.
            time.sleep(0.1 * 2**attempt)

    return failed_total, len(pending)


def main():
    args = parse_args()
    events, records_per_second, doomed = prepare_events(
        args.file, args.rate, args.fail_rate, args.seed, args.start_at, args.limit
    )
    print(
```

```
    f"sending {len(events)} records to {args.stream} ({args.region}): {args.rate} payments/s = "
    f"{records_per_second:.1f} records/s, injected failures: {doomed}",
    flush=True,
)

client = boto3.client("kinesis", region_name=args.region)
batch = []
sent = 0
failed_total = 0
undelivered = 0
started = time.monotonic()
last_flush = started

def flush():
    nonlocal batch, sent, failed_total, undelivered, last_flush
    if batch:
        failed, lost = put_batch(client, args.stream, batch)
        sent += len(batch) - lost
        failed_total += failed
        undelivered += lost
        print(
            f"batch={len(batch)} sent={sent} FailedRecordCount={failed} "
            f"failed_total={failed_total} undelivered={undelivered}",
            flush=True,
        )
        batch = []
    last_flush = time.monotonic()

try:
    for index, event in enumerate(events):
        # Той самий розклад, що в Part 3: кожен запис має свій момент відносно старту,
        # тому час самих викликів API не накопичується і темп не пливе.
        delay = started + index / records_per_second - time.monotonic()
        if delay > 0:
            time.sleep(delay)

        batch.append(to_record(event))
        if len(batch) >= MAX_BATCH or time.monotonic() - last_flush >= FLUSH_SECONDS:
            flush()
except KeyboardInterrupt:
    print("interrupted, sending the last batch", flush=True)

flush()
print(f"done: sent={sent} failed_total={failed_total} undelivered={undelivered}", flush=True)
if undelivered:
    sys.exit(1)
```

```
if __name__ == "__main__":
    main()
```

lab8/streaming/replay.py

```
"""Lab 8: спільна логіка replay для producer.py (Redpanda) і cloud/producer_kinesis.py (Kinesis).

Тут лише підготовка подій, без жодного клієнта брокера.
"""

import json
import random


def load_events(path):
    with path.open(encoding="utf-8") as file:
        events = [json.loads(line) for line in file]
    # Рядки ISO 8601 в одному форматі сортуються так само, як час, тому парсити дати не треба.
    # sort стабільний: події з однаковим receivedAt лишаються у вихідному порядку.
    events.sort(key=lambda event: event["receivedAt"])
    return events


def inject_failures(events, fail_rate, seed):
    """Перетворює success на failure для частки платежів і повертає їхню кількість."""
    # Вибираємо ПЛАТЕЖІ, а не події: дубльований success мусить змінитись разом з оригіналом,
    # інакше той самий платіж був би водночас і успішним, і невдалим.
    # sorted робить вибір детермінованим: порядок обходу set між запусками Python різний.
    successful = sorted({event["invoiceId"] for event in events if event["status"] == "success"})
    rng = random.Random(seed)
    doomed = {invoice for invoice in successful if rng.random() < fail_rate}
    for event in events:
        if event["status"] == "success" and event["invoiceId"] in doomed:
            event["status"] = "failure"
            event["finalAmount"] = 0
            event["failureReason"] = "Injected failure"
    return len(doomed)


def skip_to(events, start_at):
    """Відкидає події до першої з часом receivedAt >= HH:MM."""
    for index, event in enumerate(events):
        # Символи 11–15 рядка 2026-10-01T17:00:05Z це HH:MM. Шукаємо перший збіг, а не фільтруємо,
        # щоб не загубити хвіст після півночі: там час 00:06, але події йдуть після 23:59.
        if event["receivedAt"][11:16] >= start_at:
            return events[index:]
    return []
```

```
def prepare_events(path, rate, fail_rate=0.0, seed=42, start_at=None, limit=None):
    """Повертає (події, повідомлень за секунду, кількість зіпсованих платежів)."""
    events = load_events(path)

    # Темп задано в платежах, а надсилаємо події, яких на платіж припадає ~3.
    # Тому рахуємо реальне співвідношення і переводимо платежі/с у повідомлення/с.
    events_per_payment = len(events) / len({event["invoiceId"] for event in events})
    messages_per_second = rate * events_per_payment

    # Помилки вводимо до limit і start_at, щоб частка не залежала від шматка дня.
    doomed = inject_failures(events, fail_rate, seed) if fail_rate else 0
    if start_at:
        events = skip_to(events, start_at)
    if limit:
        events = events[:limit]
    return events, messages_per_second, doomed
```